

درس داده‌کاوی · تحلیل مجموعه داده

داده کاوی سینما

کاوش آماری و بصری در ۱٬۰۰۰ فیلم برتر IMDb؛ از پاک‌سازی داده و توزیع‌ها تا همبستگی امتیاز، محبوبیت و فروش در بازه ۲۰۰۶ تا ۲۰۱۶.

مجریان

بنیامین کشاورز
ملیکا قصاب‌نژاد
آرین بلندی

استاد درس

فرزانه استاداکبری

زمان ارائه

۸:۰۰ – ۱۰:۳۰

منبع داده

IMDb Top 1000

۱۲ ویژگی · ۱٬۰۰۰ رکورد

فهرست مطالب

مسیر ارائه در پنج بخش؛ از معرفی داده تا جمع‌بندی یافته‌ها



مقدمه — چرا IMDb؟

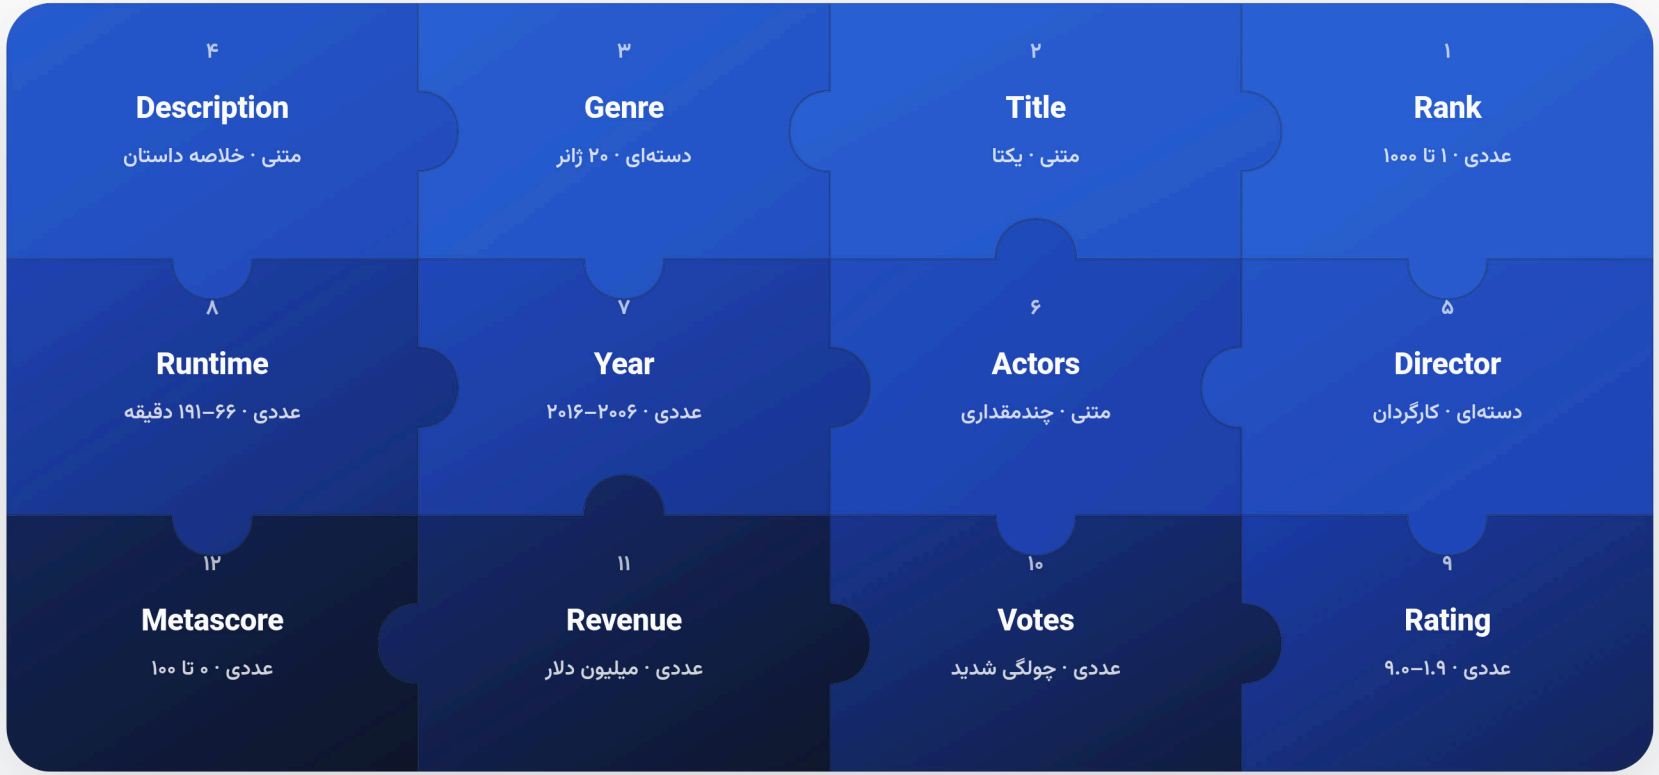
انتخاب یک مجموعه داده‌ی عمومی، پرحجم و چندنوعی برای تحلیل داده‌کاوی

حجم داده	ویژگی‌ها	بازه‌ی زمانی
۱,۰۰۰	۱۲	۱۱ سال
فیلم، بدون تکرار	عددی، دسته‌ای و متنی	۲۰۰۶ تا ۲۰۱۶

- **بزرگ‌ترین پایگاه عمومی سینما.** فهرست ۱,۰۰۰ فیلم برتر IMDb ترکیبی از سلیقه‌ی مخاطب عام و ارزیابی منتقدان است و همین دوگانگی آن را برای تحلیل جذاب می‌کند.
- **تنوع نوع داده.** ۱۲ ویژگی در چهار خانواده‌ی شناسه، متنی، دسته‌ای و عددی؛ از نام کارگردان تا فروش جهانی، همه در یک جدول.
- **بازه‌ی هدفمند ۲۰۰۶ تا ۲۰۱۶.** یازده سال متوالی که اوج فروش جهانی گیشه و آغاز سلطه‌ی پلتفرم‌های استریم را پوشش می‌دهد.
- **پرسش پژوهش.** چه عواملی با امتیاز و فروش یک فیلم همبستگی دارند و کدام متغیرها اطلاعات تکراری حمل می‌کنند؟
- **محدودیت شناخته‌شده.** این نمونه‌ی «برترین‌ها» است نه نمونه‌ی تصادفی صنعت سینما؛ بنابراین نتایج به جامعه‌ی فیلم‌های باکیفیت تعمیم‌پذیرند.

ساختار مجموعه داده

۱۲ ستون، ۱٬۰۰۰ ردیف — دو ستون عددی دارای مقدار گمشده هستند



کیفیت داده

پیش از هر تحلیلی باید بدانیم کدام ستون ناقص است و آیا رکورد تکراری وجود دارد

بررسی یکتایی و تکرار

۱,۰۰۰ ردیف — هیچ ردیف کاملاً تکراری‌ای

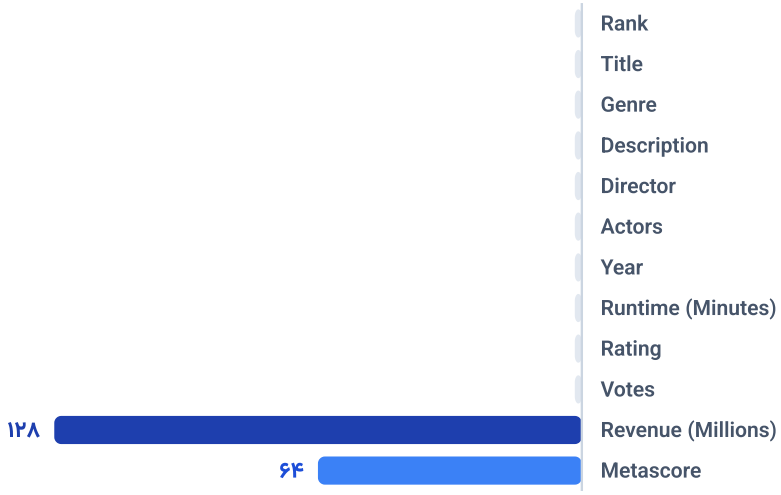


۱۰۰٪ یکتا

ردیف یکتا	۱,۰۰۰
ترکیب ژانر یکتا	۲۰۷
ستون با مقدار گمشده	۲

مجموعه داده برای تحلیل آماده است

تعداد مقدار گمشده در هر ستون



طول میله = تعداد ردیف فاقد مقدار

فروش ناقص	۱۲.۸٪	متاسکور ناقص	۶.۴٪	ردیف کامل	۸۳۸	رکورد تکراری	۰

نمای کلی — شاخص‌های کلیدی

چهار عدد که مقیاس مجموعه داده را مشخص می‌کنند

تعداد فیلم
۱,۰۰۰
کل رکوردها، بدون تکرار

میانگین امتیاز
۶.۷۲
دامنه ۱.۹ تا ۹.۰

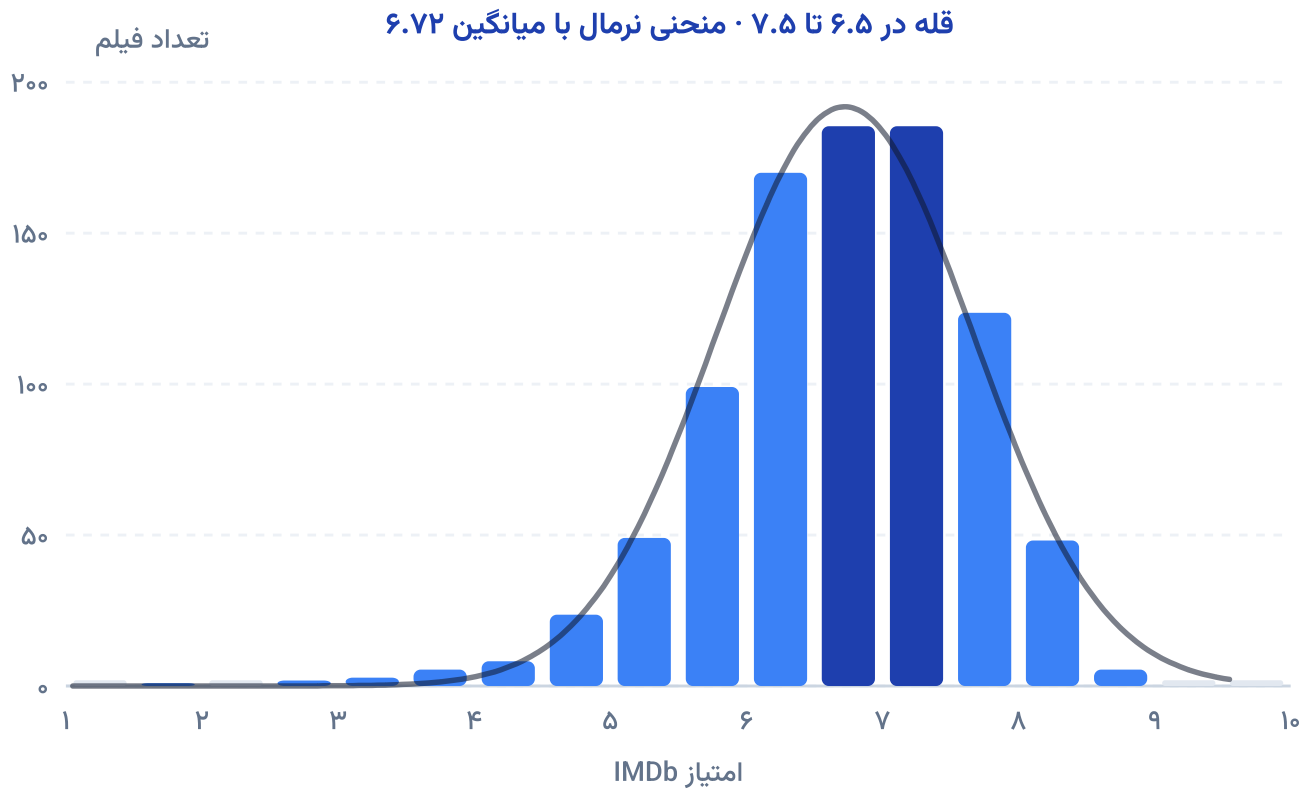
میانگین مدت زمان
۱۱۳ دقیقه
کوتاه‌ترین ۶۶ · بلندترین ۱۹۱

مجموع فروش
۷۲.۳ میلیارد دلار
میانگین هر فیلم ۸۲.۹۶ میلیون

- **نمره‌ها کمی به سمت مقادیر بالا متمایل‌اند (چولگی منفی).** میانگین (۶.۷۲) کمی از میانه (۶.۸۰) کمتر است، که همین را نشان می‌دهد. برخلاف فروش، تعداد بسیار کمی از نمره‌های خیلی بالا وجود دارد و دنبالهٔ بلندی در سمت نمره‌های بالا نیست.
- **داده‌ی نامتوازن زمانی.** ۸۰٪ فیلم‌ها در دهه‌ی ۲۰۱۰ منتشر شده‌اند و سال ۲۰۱۶ به‌تنهایی ۲۹.۷٪ حجم نمونه را می‌سازد.
- **فروش روی زیرمجموعه محاسبه شده است.** ۱۲۸ رکورد فروش خالی است؛ همه‌ی آمار فروش در این ارائه بر پایه‌ی ۸۷۲ فیلم با داده‌ی موجود است.

توزیع امتیازها

هیستوگرام با بازه‌های ۰.۵ واحدی و منحنی نرمال برازش‌شده



میانگین امتیاز	**۶.۷۲**
میانه	**۶.۸۰**
انحراف معیار	**۰.۹۵**
فیلم‌های با امتیاز ۸ و بیشتر	**۷۸**

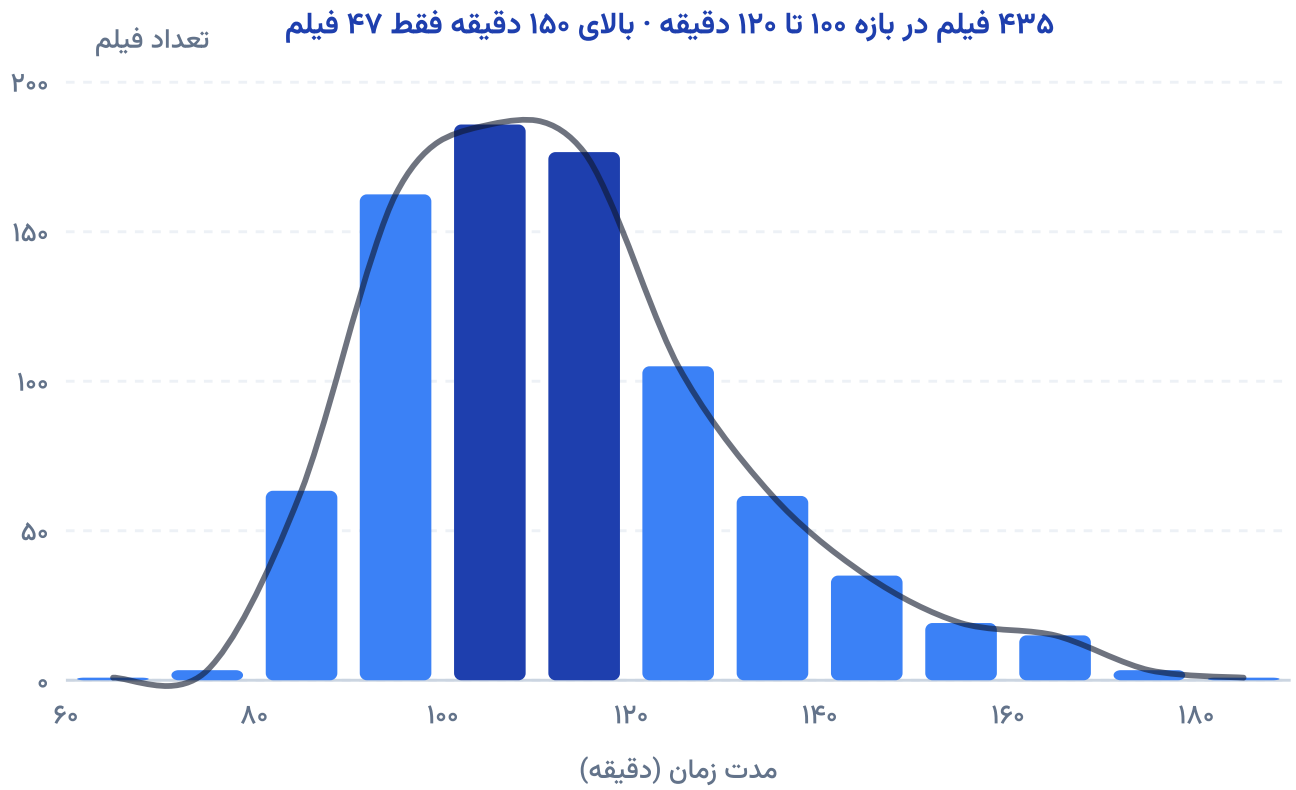
قله‌ی توزیع در بازه‌ی **۶.۵ تا ۷.۵** است و **۷۳٪** فیلم‌ها بین ۶ تا ۸ قرار می‌گیرند؛ بالای ۸.۵ تنها **۶** فیلم ایستاده‌اند.

توزیع مدت زمان

هیستوگرام با بازه‌های ۱۰ دقیقه‌ای و منحنی چگالی هموارشده

میانگین	۱۱۳.۲ دقیقه
میانه و انحراف معیار	۱۸.۸ · ۱۱۱
فیلم‌های بالای ۱۵۰ دقیقه	۴۷
چولگی توزیع	۰.۸۵

بازه‌ی **۱۰۰ تا ۱۲۰ دقیقه** با ۴۳۵ فیلم (۴۳.۵٪) پرتراکم‌ترین ناحیه است؛ فیلم‌های کوتاه‌تر از ۸۰ دقیقه فقط **۵** مورد هستند.



توزیع سال انتشار

تعداد فیلم به تفکیک سال (ستون) و میانگین امتیاز همان سال (خط)

۲۰۱۶ رکورددار با ۲۹۷ فیلم — میانگین امتیاز ۶.۴۴



پرتراکم‌ترین سال	۲۰۱۶ · ۲۹۷
سهم دهه‌ی ۲۰۱۰	۸۰٪
کمترین سال	۲۰۰۶ · ۴۴
همبستگی سال با امتیاز	-۰.۲۱

با نزدیک شدن به ۲۰۱۶ حجم نمونه زیاد می‌شود اما میانگین امتیاز از **۷.۱۳** در ۲۰۰۶ به **۶.۴۴** در ۲۰۱۶ افت می‌کند.

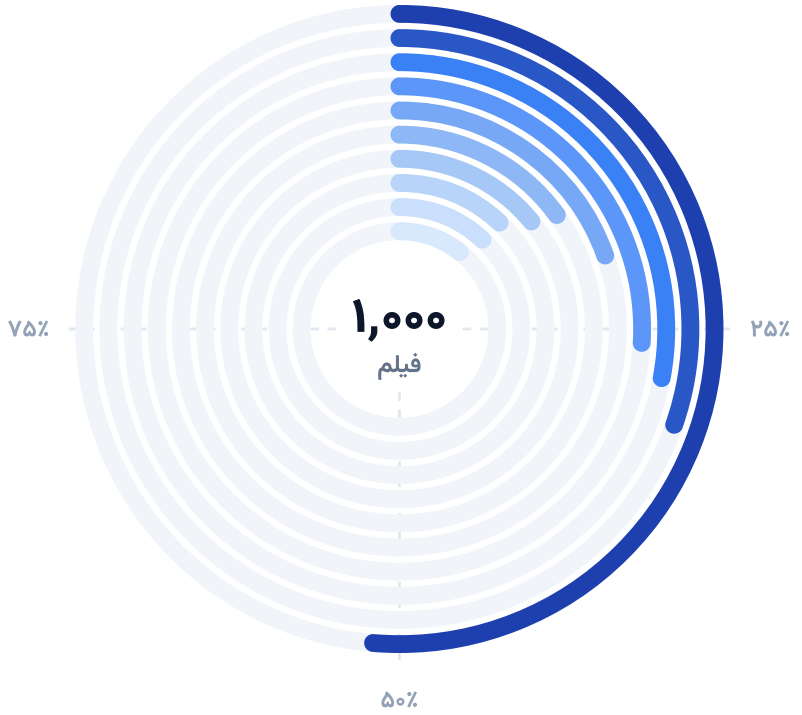
توزیع ژانرها

سهم هر ژانر از ۱,۰۰۰ فیلم — ستون Genre پس از explode شدن به ۲۰ ژانر مستقل

ژانر	تعداد	درصد
Drama	۵۱۳	۵۱.۳٪
Action	۳۰۳	۳۰.۳٪
Comedy	۲۷۹	۲۷.۹٪
Adventure	۲۵۹	۲۵.۹٪
Thriller	۱۹۵	۱۹.۵٪
Crime	۱۵۰	۱۵.۰٪
Romance	۱۴۱	۱۴.۱٪
Sci-Fi	۱۲۰	۱۲.۰٪
Horror	۱۱۹	۱۱.۹٪
Mystery	۱۰۶	۱۰.۶٪

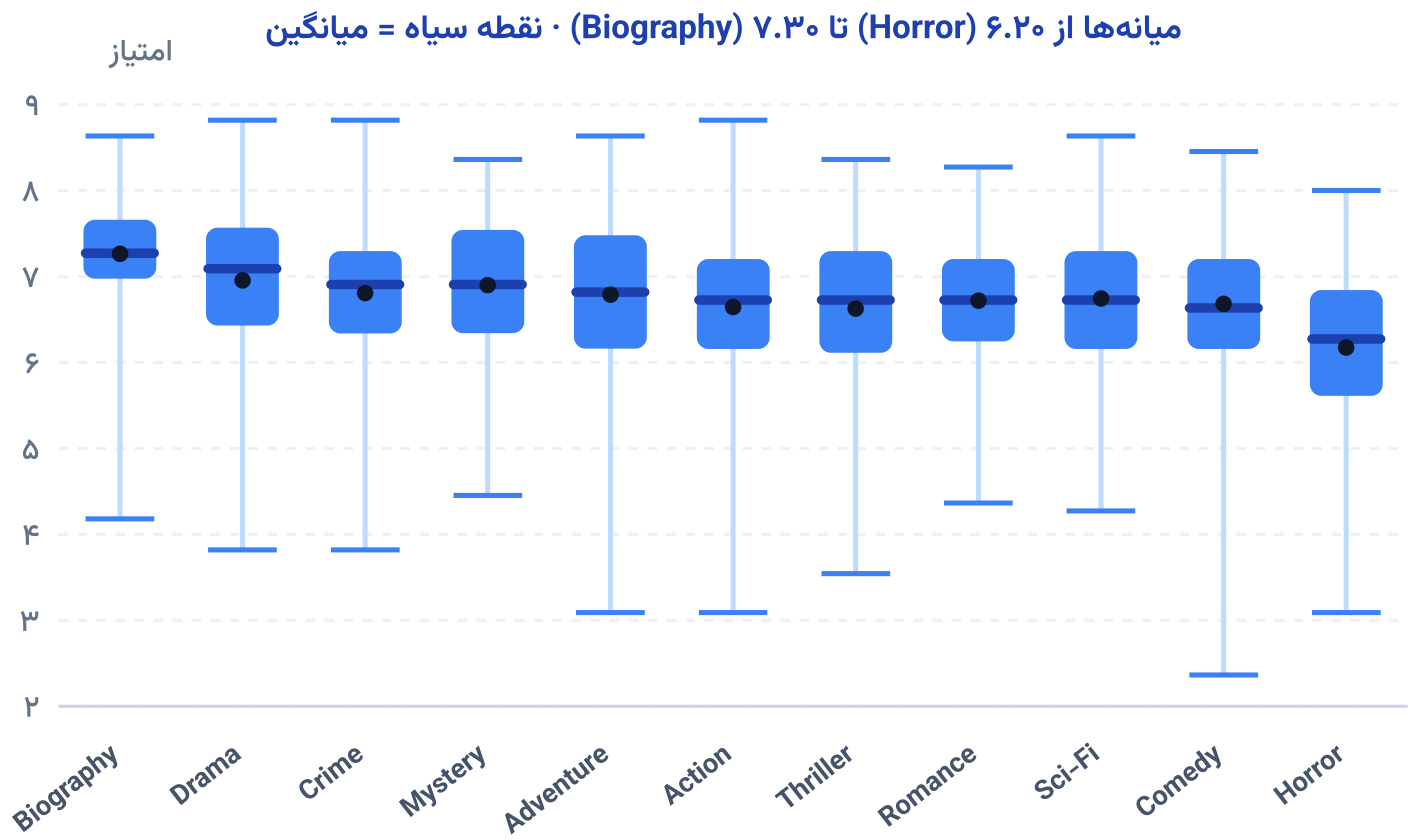
هر فیلم می‌تواند چند ژانر داشته باشد؛ پس مجموع درصدها از ۱۰۰ بیشتر می‌شود و **Drama** در بیش از نیمی از فیلم‌ها حاضر است.

طول هر کمان = درصد فیلم‌هایی که آن ژانر را دارند



همبستگی ژانر × امتیاز

نمودار جعبه‌ای امتیاز برای ۱۱ ژانر پرتکرار، مرتب‌شده بر اساس میانه

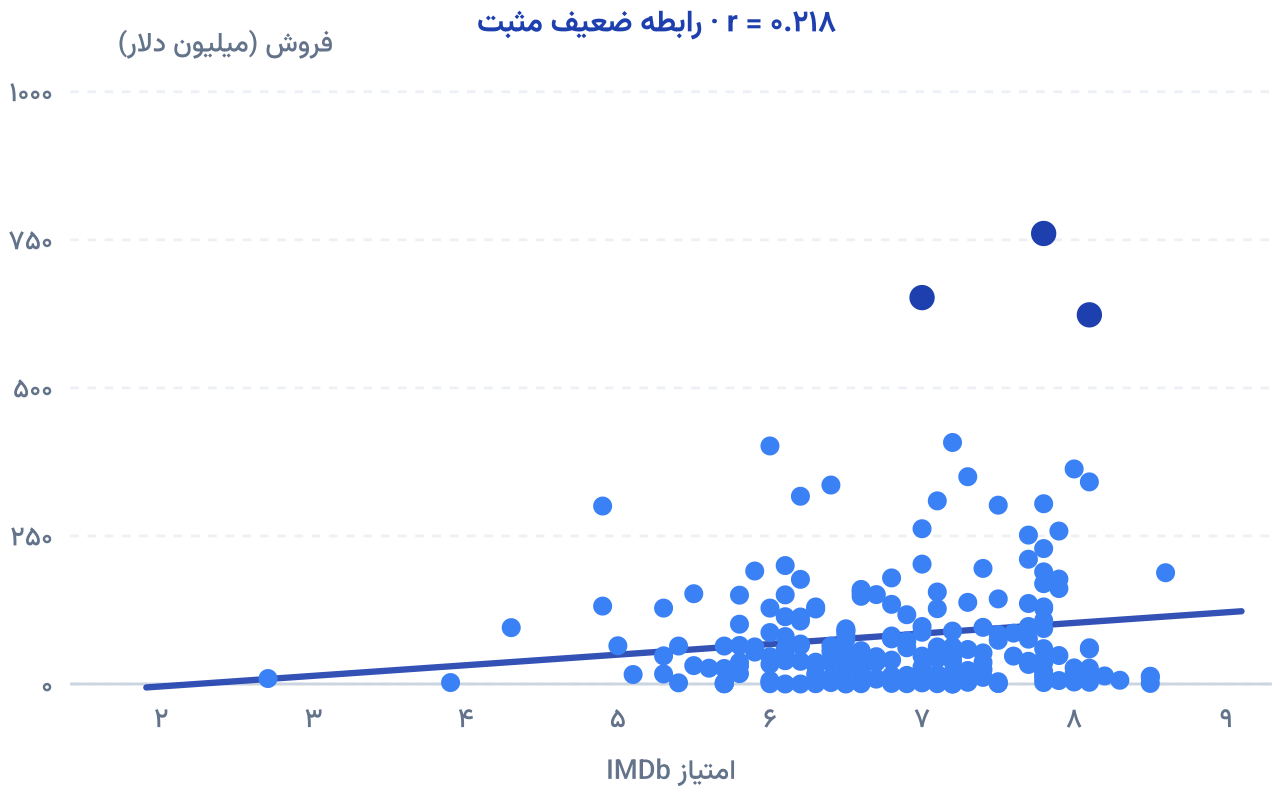


بالاترین میانه	**Biography · ۷.۳۰**
دومین	**Drama · ۷.۱۰**
پایین‌ترین میانه	**Horror · ۶.۲۰**
دامنه‌ی میانه‌ها	**۱.۱۰**

فاصله‌ی میانه‌ها کم است اما جعبه‌ها هم‌پوشانی زیادی دارند؛ ژانر **به‌تنهایی** توضیح‌دهنده‌ی قدرتمندی برای امتیاز نیست.

امتیاز vs فروش

نمودار پراکندگی ۲۲۰ فیلم نمونه با خط رگرسیون و ضریب پیرسون



ضریب پیرسون (r)	۰.۲۱۸
ضریب تعیین (R^2)	۴.۷٪
بیشترین فروش	۹۳۶.۶M
نقطه‌های پرت	۴

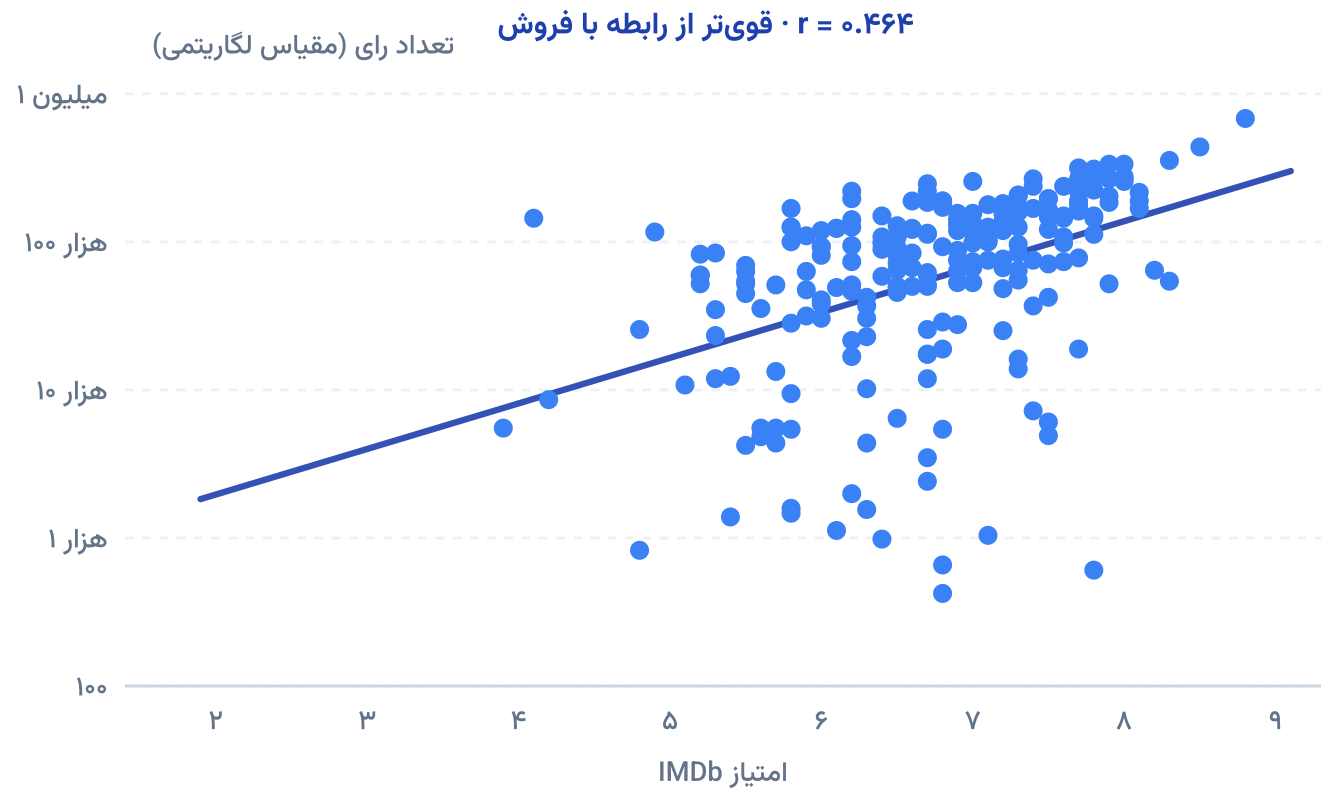
رابطه **ضعیف و مثبت** است: امتیاز فقط ۴.۷٪ تغییرات فروش را توضیح می‌دهد. Avatar با ۷.۸ و ۷۶۰ میلیون، از The Dark Knight با ۹.۰ و ۵۳۳ میلیون جلوتر است.

امتیاز vs رای‌ها

محور عمودی لگاریتمی است؛ بدون لگاریتم چند نقطه تمام نمودار را می‌بلعیدند

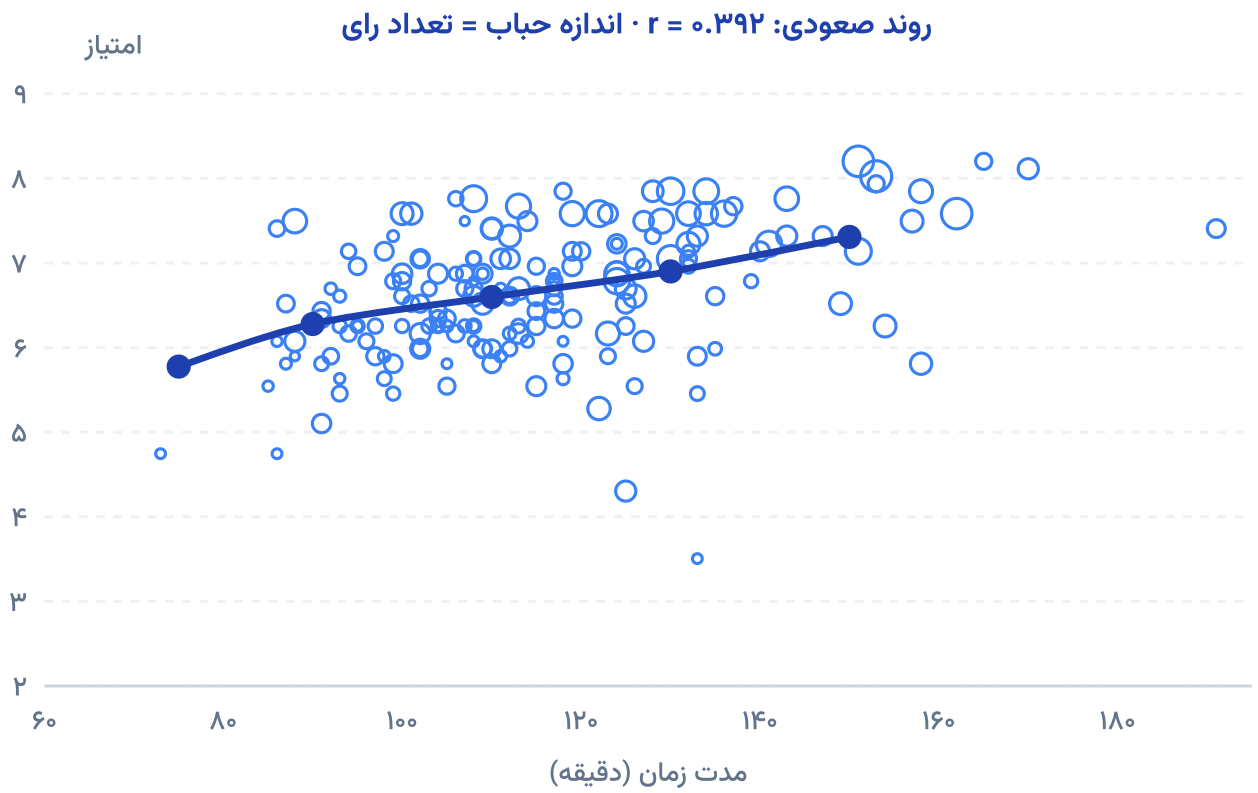
r روی مقیاس لگاریتمی	۰.۴۶۴
r روی داده‌ی خام	۰.۵۱۲
میانه‌ی رای‌ها	۱۱۰,۷۹۹
بیشترین رای	۱,۷۹۱,۹۱۶

محبوبیت با کیفیت هم‌راستاتر است تا با فروش: ضریب **۰.۴۶** در برابر **۰.۲۲**. یعنی مخاطب پرشمار فیلم خوب را می‌بیند، ولی فروش بیشتر تابع عوامل دیگری است.



مدت زمان vs امتیاز

حباب‌ها به‌اندازه‌ی ریشه‌ی تعداد رای‌ها هستند؛ خط، میانگین امتیاز هر بازه است



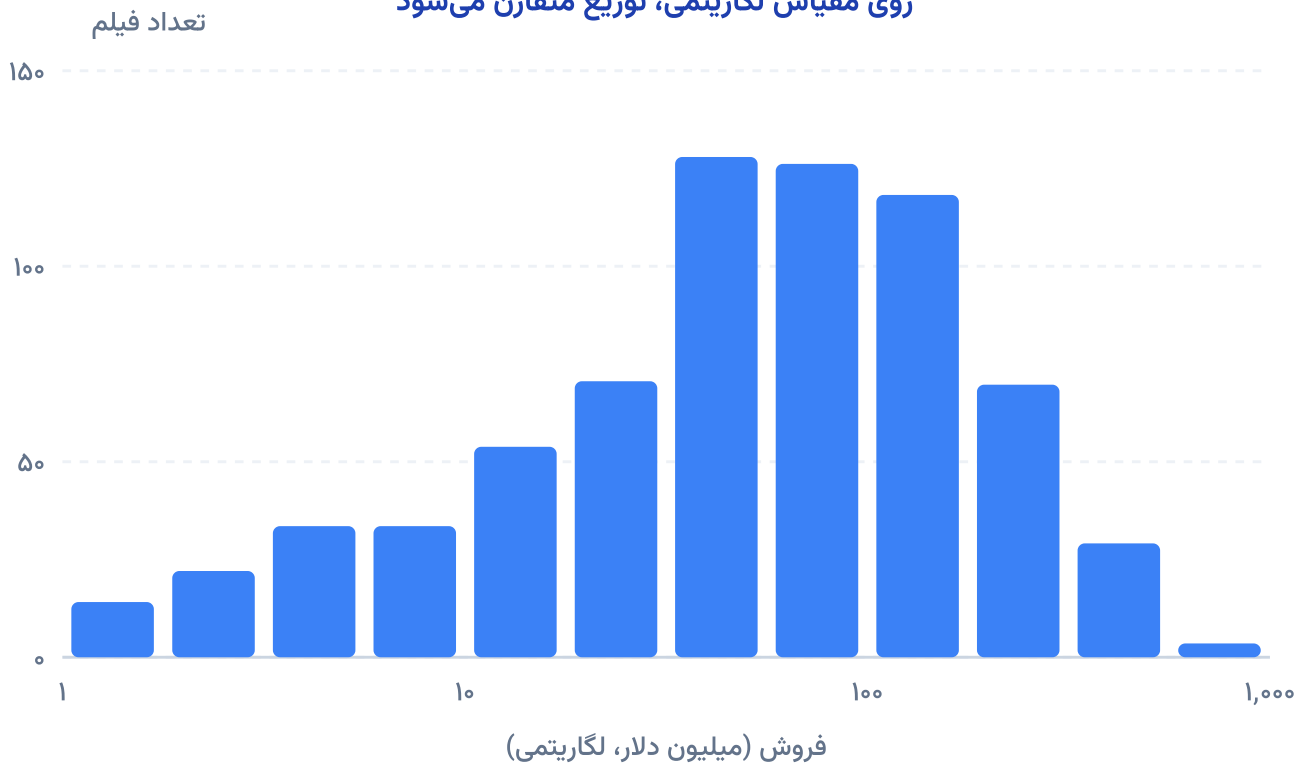
ضریب پیرسون	۰.۳۹۲
زیر ۸۰ دقیقه	۵.۷۶
۱۰۰ تا ۱۲۰ دقیقه	۶.۶۹
بالای ۱۴۰ دقیقه	۷.۴۹

یافته برخلاف انتظار اولیه است: رابطه **مثبت و یکنوا**؛ هرچه فیلم بلندتر، میانگین امتیاز بالاتر. «نقطه‌ی شیرین» ۱۰۰ تا ۱۲۰ دقیقه مربوط به **بیشترین فراوانی** است نه بالاترین امتیاز.

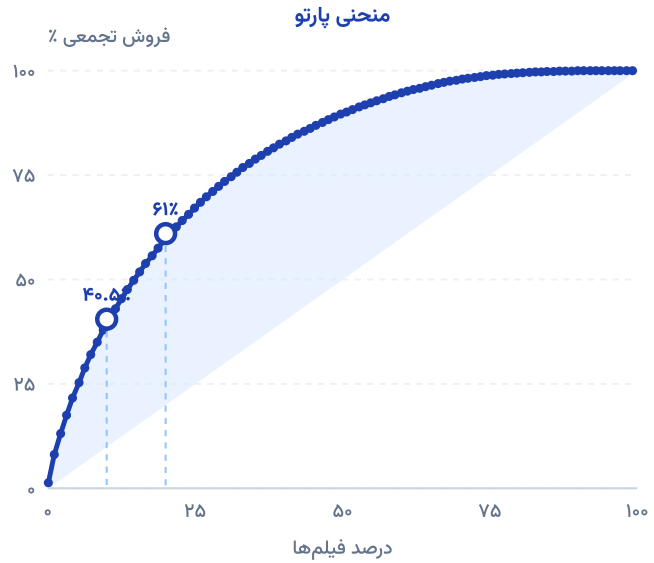
فروش — تحلیل چولگی

هیستوگرام روی مقیاس لگاریتمی (چپ) و منحنی تجمعی پارتو (راست)

روی مقیاس لگاریتمی، توزیع متقارن می‌شود



منحنی پارتو



۱۰٪ پرفروش‌ترین فیلم‌ها **۴۰.۵٪** کل فروش را می‌سازند و ۲۰٪ نخست به **۶۱٪** می‌رسند؛ توزیع به‌شدت دنباله‌دار است و میانگین (۸۳) بالاتر از میانه (۴۸) می‌نشیند.

چولگی	میانه	میانگین
۲.۵۹	۴۸.۰M	۸۳.۰M

ماتریس همبستگی

ضریب پیرسون میان شش ویژگی عددی؛ شدت رنگ نشان‌دهنده‌ی قدرت رابطه است

آبی = رابطه مستقیم · قرمز = رابطه معکوس · شدت رنگ = قدرت رابطه

	متا	فروش	رای	امتیاز	مدت	سال
سال	-۰٫۰۸	-۰٫۱۳	-۰٫۴۱	-۰٫۲۱	-۰٫۱۷	
مدت	۰٫۲۱	۰٫۲۷	۰٫۴۱	۰٫۳۹		-۰٫۱۷
امتیاز	۰٫۶۳	۰٫۲۲	۰٫۵۱		۰٫۳۹	-۰٫۲۱
رای	۰٫۳۳	۰٫۶۴		۰٫۵۱	۰٫۴۱	-۰٫۴۱
فروش	۰٫۱۴		۰٫۶۴	۰٫۲۲	۰٫۲۷	-۰٫۱۳
متا		۰٫۱۴	۰٫۳۳	۰٫۶۳	۰٫۲۱	-۰٫۰۸

قوی‌ترین جفت‌ها: رای ↔ فروش (۰.۶۴) و امتیاز ↔ متاسکور (۰.۶۳)

رای ↔ فروش	۰.۶۴۰
امتیاز ↔ متاسکور	۰.۶۳۲
امتیاز ↔ رای	۰.۵۱۲
امتیاز ↔ مدت زمان	۰.۳۹۲

دو جفت قوی، هر دو **مصنوعی‌اند نه علّی**: رای زیاد هم فروش می‌آورد و هم نشانه‌ی دیده‌شدن است. ضعیف‌ترین رابطه، سال با متاسکور (**-۰.۰۸**) است.

۱۰ فیلم برتر

مرتب‌شده بر اساس امتیاز IMDb؛ سال، تعداد رای و فروش هر فیلم

۱. **The Dark Knight** — ۲۰۰۸ · ۱,۷۹۱,۹۱۶ رأی · ★ ۹.۰ · ۵۳۳٫۳۲M



۲. **Inception** — ۲۰۱۰ · ۱,۵۸۳,۶۲۵ رأی · ★ ۸.۸ · ۲۹۲٫۵۷M



۳. **Dangal** — ۲۰۱۶ · ۴۸,۹۶۹ رأی · ★ ۸.۸ · ۱۱٫۱۵M



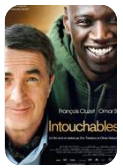
۴. **Interstellar** — ۲۰۱۴ · ۱,۰۴۷,۷۴۷ رأی · ★ ۸.۶ · ۱۸۷٫۹۹M



۵. **Kimi no na wa** — ۲۰۱۶ · ۳۴,۱۱۰ رأی · ★ ۸.۶ · ۴٫۶۸M



۶. **The Intouchables** — ۲۰۱۱ · ۵۵۷,۹۶۵ رأی · ★ ۸.۶ · ۱۳٫۱۸M



۷. **The Prestige** — ۲۰۰۶ · ۹۱۳,۱۵۲ رأی · ★ ۸.۵ · ۵۳٫۰۸M



۸. **The Departed** — ۲۰۰۶ · ۹۳۷,۴۱۴ رأی · ★ ۸.۵ · ۱۳۲٫۳۷M



۹. **The Dark Knight Rises** — ۲۰۱۲ · ۱,۲۲۲,۶۴۵ رأی · ★ ۸.۵ · ۴۴۸٫۱۳M

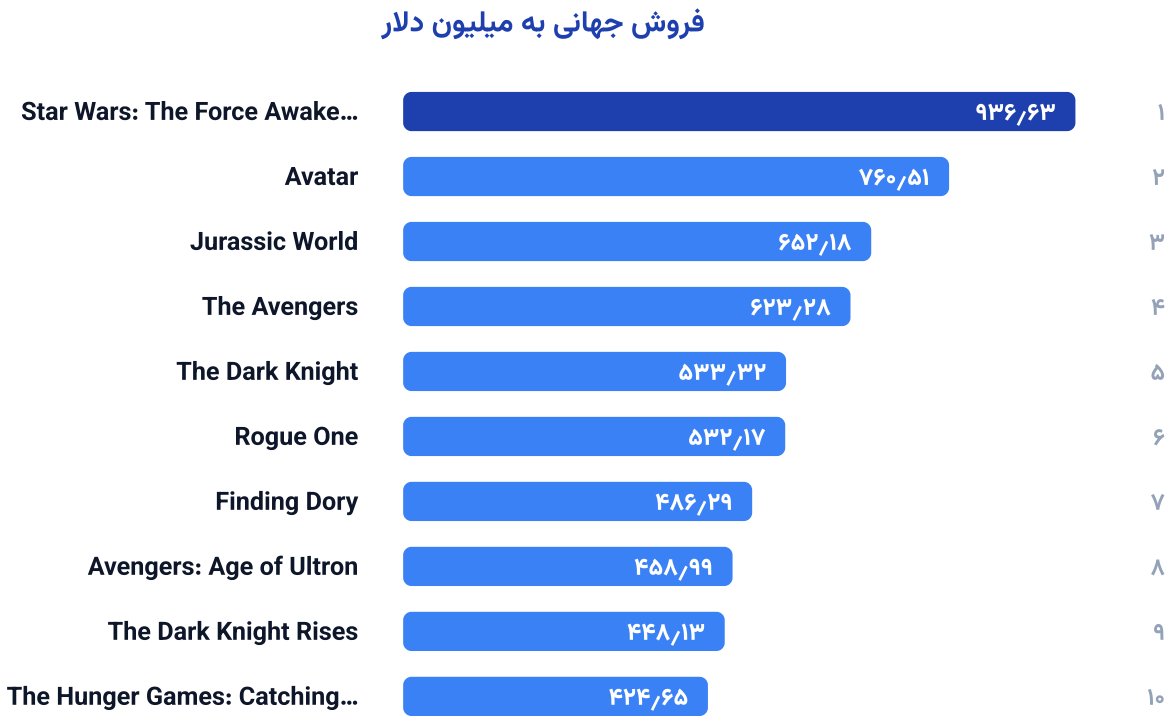


۱۰. **Whiplash** — ۲۰۱۴ · ۴۷۷,۲۷۶ رأی · ★ ۸.۵ · ۱۳٫۰۹M



۱۰ فیلم پرفروش

فروش جهانی به میلیون دلار — تنها فیلم‌هایی که داده‌ی فروش دارند



پرفروش‌ترین	۹۳۶.۶M
بالای ۵۰۰ میلیون	۶ فیلم
میانگین ۱۰ فیلم	۵۸۵.۶M
میانگین امتیاز آن‌ها	۷.۸۸

نتیجه‌گیری — چهار یافته کلیدی

آنچه داده در این ۱٬۰۰۰ رکورد به ما گفت

۰۱ — ژانر غالب

Drama صحنه را در دست دارد

۵۱۳ فیلم از ۱٬۰۰۰ حداقل یک ژانر درام دارند و میانه‌ی امتیازشان ۷.۱۰ است؛ Biography با ۷.۳۰ بالاترین میانه را دارد و Horror با ۶.۲۰ پایین‌ترین.

۰۲ — کیفیت در برابر فروش

دو دنیای متفاوت

r امتیاز با فروش فقط ۰.۲۲ است؛ اما با لگاریتم رای‌ها به ۰.۴۶ می‌رسد. فروش بیشتر به مقیاس اکران و برند اثر وابسته است تا به امتیاز.

۰۳ — توزیع فروش

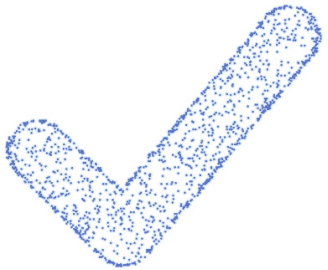
فروش به‌شدت نامتقارن است

چولگی ۲.۵۹ (مثبت و بزرگ) نشان می‌دهد دنبالهٔ توزیع به سمت فروش‌های خیلی بالا کشیده شده است. میانگین ۸۳ میلیون در برابر میانه ۴۸ میلیون هم همین را تأیید می‌کند؛ چون چند فروش بسیار بالا میانگین را بالا برده‌اند. ۱۰٪ پرفروش‌ترین‌ها ۴۰.۵٪ کل گیشه را می‌سازند. به همین دلیل دادهٔ فروش را باید با مقیاس لگاریتمی تحلیل کرد یا از مدل‌های مقاوم (مقاوم به داده‌های پرت) استفاده کرد.

۰۴ — مدت زمان

سیگنال ضعیفِ معنادار

همبستگی ۰.۳۹ و میانگین امتیاز از ۵.۷۶ (زیر ۸۰ دقیقه) تا ۷.۴۹ (بالای ۱۴۰ دقیقه). طول فیلم شاخصی از بلندپروازی پروژه است، نه تضمین کیفیت.



با تشکر از توجه شما

آماده‌ی پرسش و پاسخ هستیم — پرسش‌ها می‌توانند درباره‌ی روش پاک‌سازی، انتخاب آزمون همبستگی یا تفسیر یافته‌ها باشند.

بنیامین کشاورز
ملیکا قصاب‌نژاد
آرین بلندی

استاد: فرزانه استاداکبری
زمان ارائه: ۸:۰۰ – ۱۰:۳۰